

Plano de Arquitetura de Software — SaaS Multi-tenant

O Orchestrator é um sistema de **orquestração de agentes de IA** com catálogo declarativo de **861 agentes** (fonte canônica: `agents.json`, validado por JSON Schema Draft 2020-12) e núcleo `orchestrator.py` com **5.717 linhas** (v4.46.0).

Qualidade verificável

- **727 testes** automatizados no gate oficial.
- Cobertura medida de **100%** do núcleo (`orchestrator.py`, `durable_queue.py`, `validate_agents.py`).
- Gate bloqueante: `--cov-fail-under=90`; E2E do bridge: **21/21**.

Componentes

- **Roteador híbrido**: casamento por palavra (word boundary) com score de **especificidade** (raridade $\times$ nº de palavras), **confiança explícita 0–1** (margem sobre o 2º colocado + força do sinal), corroboração de squad e resgate **semântico opt-in** (TF-IDF cosseno ou embeddings via API) antes do fallback genérico.
- **Tiering cognitivo de modelos**: cada passo é classificado por complexidade e executado no tier **economy/standard/strong**. O avaliador `_evaluate_output` reprova saída insuficiente $\rightarrow$ retenta e escala de tier automaticamente.
- **Governança de custo**: 4 tetos (`MAX_COST_USD_PER_RUN`, `MAX_TOKENS_PER_RUN`, unidades por domínio e por agente) com políticas abort/downgrade/notify; metering real de tokens e US\$ por tier no ledger.
- **Resiliência**: fila durável SQLite com leases e reclaim, ledger de eventos append-only, `--replay` de auditoria e `--resume` idempotente — passos concluídos nunca repetem.
- **Executor LLM**: endpoint OpenAI-compatible (`EXEC_LLM_URL`) com cadeia de fallback de modelos, retry com delay, cache de resposta keyed por hash(modelo+mensagens) e latência medida por tentativa.
- **Fallback em 3+1 camadas**: declarativo (`fallbackTo`), por saúde/quarentena das últimas execuções, em runtime (re-checado a cada passo) e a cadeia de modelos do executor.
- **Registry de delegação**: `subagent_registry.json` valida o `subagent_type` antes do despacho.
- **Coordenação**: Devin CLI (código), microserviço Devin :5050 (marketing/texto) e n8n (automação).
- **Observabilidade**: métricas append-only em JSONL, exportação Prometheus, 21 painéis Grafana (custo por tier, economia estimada vs all-strong, latência do executor, conflitos de squad), logs estruturados e saúde persistente.
- **Voz nativa**: comando 00001 com transcrição local e TTS pt-BR.

Precisão técnica: o roteamento é determinístico por padrão (keyword + especificidade); a camada semântica (TF-IDF ou embeddings) é **opt-in** e também auditável. O termo 'orquestração neural' é de posicionamento de produto, não de implementação.

Limitações conhecidas

- O cliente fornece as próprias chaves de API do provedor de IA (padrão de mercado).
- Os motores de engenharia CAD (FreeCAD/CalculiX/KiCad) estão em processo de validação; saídas são ponto de partida.
- O catálogo é amplo (861 agentes) e heterogêneo em profundidade de descrição; curadoria é contínua.